本文章已註冊DOI數位物件識別碼

airiti Library

是誰評判不公

Who is Unfair?

doi:10.6773/JRMS.200212.0121

測驗統計年刊, (10), 2002

Journal of Research on Measurement and Statistics, (10), 2002

作者/Author： 曾盟堡(Meng-Pao Tseng)

頁數/Page： 121-133

出版日期/Publication Date：2002/12

引用本篇文獻時，請提供DOI資訊，並透過DOI永久網址取得最正確的書目資訊。

To cite this Article, please include the DOI name in your reference data.

請使用本篇文獻DOI永久網址進行連結:

To link to this Article:

http://dx.doi.org/10.6773/JRMS.200212.0121

DOI Enhanced

DOI是數位物件識別碼（Digital Object Identifier, DOI）的簡稱，
是這篇文章在網路上的唯一識別碼，
用於永久連結及引用該篇文章。

若想得知更多DOI使用資訊，

請參考 http://doi.airiti.com

For more information,

Please see: http://doi.airiti.com

請往下捲動至下一頁，開始閱讀本篇文獻

PLEASE SCROLL DOWN FOR ARTICLE

最完整的學術整合查詢平台—華藝線上圖書館 ● http://www.airitilibrary.com ● Find more academic articles on Airiti Library

是誰評判不公

曾盟堡

南投縣永樂國民小學

摘要

本研究旨在利用試題反應理論分析裁判的判決。以第十三屆亞洲運動會舞蹈運動標準舞比賽決賽裁判員裁決情形爲分析資料。利用 FACETS 軟體進行多層面 Rasch 模式分析, 檢定「適合度統計」、「非期望反應」。研究發現有二位裁判員評判不公及六個非期望反應判決, 其非期望反應判決的原因應爲系統性誤差、誤判或筆誤所致。

關鍵字: 試題反應理論、判決行爲、舞蹈運動、適合度統計。

C.E.P.S.

第一節　緒論

2002 年鹽湖城冬季奧運雙人花式滑冰決賽, 加拿大選手幾乎無瑕疵的完美演出, 博得觀眾與媒體一致讚賞, 卻爆出冷門, 由俄羅斯選手繼續十一連霸, 加拿大選手則悲傷落淚屈居第二。賽後, 法國代表團內部傳出法籍裁判 Lakernik 趁執法之便, 在比賽中給予特定選手高分, 藉以討好俄羅斯與其他東歐國家, 交換法國選手在其他項目奪牌 (自由時報, 民 91)。消息傳來, 引起各界撻伐攻訐及國際奧會的強烈關切。喧騰數日之後, 國際奧會決定開除一名「執法不公」的裁判, 並加發金牌乙面, 以消弭各方雜音 (中國時報, 民 91)。

雙人冰舞事件起因於裁判評判不公。「裁判」一直是測量 (或比賽) 中相當重要的一環, 執法的良莠影響了整個品質。爲了測量品質的監控, 實施標準化的客觀測驗 (objective test), 當然會是測量的一個理想, 但是仍有許多事項 (例如體操、作文、歌曲演唱等) 無法以客觀測驗施測, 需要專業人員就其專業知能以「人爲方式」來進行評判。

這種方式, 衍生出問題來: 是誰評判不公? 又如何檢測得知?

通常, 裁判會依循共同的客觀效標, 以個人獨立觀點行使專業知能, 雖非全然自由心證, 但是的確不易指證裁判員評判有誤或立場不公有所偏袒。

傳統上以評分者一致性 (含評分者內及評分者間) 來表示整個評判品質的優劣, 即一致性愈高表示裁判員的看法愈一致, 評判的品質愈好。但是當「系統性誤差」存在時 (例如白人裁判歧視黑人選手) 或受試者時運不濟前後被兩位給分嚴苛的裁判評閱時, 二次評分所求得的評分者一致性可能相當高但受試者原始得分卻未必能反映眞正實力。錯誤或偏頗的評判仍包含在整體的評判品質之內無法顯現。

面對這的問題, 古典測驗理論提不出一個有效的解決辦法, 於是 Lunz 等人 (1990) 改採多層面 Rasch 模式 (Many-facet Rasch model) 來進行分析。

Lunz 等人 (1990) 以 217 名受試者, 每個人需製作十五張幻燈片的證照考試進行研究, 使用 FACETS 軟體分析。研究發現有一位評審員尺度太寬鬆, 三位太嚴苛, 其他十四位則表現正常。

Looney(1996) 分析 1994 年女子溜冰比賽, 比賽項目分爲指定動作與自由動作二項, 使用 FACETS 部份計分評分量尺 (partial-credit rating scale) 模式分析。研究發現, 對裁判員而言, 指定動作較難以評比; 在 459 筆的評判中只有五次非期望的不當判決, 原因是普通選手被意外地評了高分。另外, 發現英國和加拿大裁判員的變異較大, 偏

離反應值 (OUTFIT) 達 1.2, 原因可能來自裁判員對選手的熟悉情形、裁判員本身的經驗水準、和與其他裁判員評比結果不一致的心理壓力等。

Engelhard(1992) 以喬治亞地區一千位八年級學生爲受試者進行寫作能力測驗, 仍使用 FACETS 進行分析。結果發現評審員的差異達到顯著水準, 且有七位評審員不良。Engelhard 以第五十九號評審員爲範例, 追蹤找到該員 15 個「非期望反應」的評分。對於學生作品非期望的得分, Engelhard認爲應當再調閱學生作品仔細檢查, 推測其發生原因爲「離題」、「字體潦草難以辨認」和「文章內容含有爭議性」等。

國內學者何榮桂、姚漢禱 (民 85) 運用試題反應理論 (Item Response Theory) 以大學體育興趣選項桌球班的發長球測驗 213 人爲研究對象, 檢測出一人偏離反應值大於 5 嚴重不適合模式而予以拒絕; 另有十二人的偏離反應值在 3 ～ 5 之間爲不適合模式資料, 列爲注意觀察對象。再深入追蹤這十二人的反應類型, 診斷得知造成不適合模式的主要原因爲「發球失誤」。

林德隆 (民 88) 以 637 名國中男生爲受試對象編製國中壘球擲準測驗, 以 FACETS 初步估計後決定刪除六十名不適當的受試者和二次不良的擲準試做。重新再行估計, 結果發現模式資料適合得更好, 估計的精確度更高。

葉憲清、姚漢禱 (民 89) 選手評鑑運動教練的多層面 Rasch 測量分析報告, 從 470 名受試者中檢測出七名受試者列爲小心檢查反應類型對象; 在量表的試題部份, 檢測出二題爲很不適合模式的試題, 六題應謹慎檢查其反應類型, 可能爲不適合的試題。

由上文可以得知試題反應理論適合用以檢測資料中非期望的表現。因此, 本文以第十三屆亞洲運動會舞蹈運動比賽標準舞決賽裁判之判決爲一案例, 運用 FACETS 軟體進行多層面 Rasch 模式分析, 分析的重點放在裁判員之上, 嘗試檢測是否眞有人評判不公並推測其可能原因。

第二節　研究方法

壹、資料來源

本研究以楊昌雄 (民 89) 發表於中華體育季刊「第十三屆亞洲運動會舞蹈運動比賽裁判分析」之標準舞比賽裁判判決表, 經楊昌雄校對並同意使用後做爲本研究分析資料。

C.E.P.S.

貳、資料處理

本研究採用 FACETS 3.20 版 (1999b) 進行多層面 Rasch 模式分析, 三個層面爲: 舞者 (六隊)、舞蹈 (五種舞蹈)、裁判員 (九位)。適合度統計 (偏離反應值 OUTFIT) 依 Wright & Masters(1982) 判斷的原則, 設定在 +2 到 −2。

第三節　結果與討論

FACETS 軟體首先以「概略法 (PROX)」進行估計, 經四次迭代 (iteration) 達到粗略聚斂。接著進行「非條件化最大近似值法 (UCON)」, 經過五十四次迭代達到聚斂要求完成精確估計。

適合度統計的偏離反應均方的期望值爲一。估計結果三個層面的偏離反應均方的平均爲 1.0, 標準差分別爲 0.4、0.1 和 0.7 (詳見表一、二、三)。數值接近期望值, 顯示估計結果資料適合 Rasch 模式, 可以用 Rasch 模式進行分析。

各層面經校準 (calibration) 至共同量尺 (scale) 之情形如圖一所示。

C.E.P.S.

```
|Measr|-Dancer  |-Rater                          |-Item                                          |
+   3 +        +                                +                                               +
|     |        |                                |                                               |
|     |台北121 |                                |                                               |
|     |中國101 |                                |                                               |
+   2 +        +                                +                                               +
|     |        |                                |                                               |
+   1 +中國102 +                                +                                               +
|     |        |                                |                                               |
*   0 *        *  英日新台馬泰港中韓            * 快步舞  慢狐步  探戈  維也納華爾滋  華爾滋     *
|     |        |                                |                                               |
+  -1 +        +                                +                                               +
|     |泰國124 |                                |                                               |
|     |印尼107 |                                |                                               |
+  -2 +        +                                +                                               +
|     |        |                                |                                               |
+  -3 +        +                                +                                               +
|     |        |                                |                                               |
+  -4 +        +                                +                                               +
|     |泰國125 |                                |                                               |
+  -5 +        +                                +                                               +
|Measr|-Dancer  |-Rater                          |-Item                                          |
```

圖一　各層面對照圖

圖一的特殊之處是舞蹈層面和裁判員層面估計能力所得均爲零，而且估計的標準差都相等 (詳見表一、表二)。裁判員層面，「估計的能力」值指的是裁判員的「評分者嚴苛度 (judge severity)」; 舞蹈層面,「估計的能力」值指的是舞蹈的「試題難度 (difficulty)」。一般而言，試題、評分者均具有不同程度的難度值在，舞者必需克服舞蹈難度 (相當於答對某一試題)，並跨越評分者嚴苛度 (相當於作答內容或風格符合閱卷者偏好或品味) 方能勝出奪得高分。然而估計所得評分者嚴苛度和試題難度都等於零，表示裁判員一樣嚴苛或寬鬆，而五式舞蹈 (試題) 難度相同，表示沒有哪一種舞蹈特別難跳或

容易跳。

此一情況頗爲奇特，究其成因乃比賽採「強迫排名 rank order」評分制度使然。因爲強迫排名，名次不得並列，致使每一位裁判員評出的等第整體而言相同 (評判結果都是第一名到第六名)；換個角度看，每一道試題 (舞蹈) 對舞者施測所得的結果也相仿，因此估計結果等於零、估計的標準差相等。這是強迫排名的特殊之處 (Linacre, 1989)。

表一、舞蹈層面估計摘要

舞　蹈	估計的能力	估計的標準誤	偏離反應	
			均方	標準化分數
華爾茲 (Waltz)	.00	.18	1.0	0
探戈 (Tango)	.00	.18	0.8	0
維也納華爾茲 (Viennese Waltz)	.00	.18	1.1	0
慢狐步 (Slow Foxtrot)	.00	.18	1.1	0
快步舞 (Quick Step)	.00	.18	0.8	−1
平均數	.00	.18	1.0	−0.2
標準差	.00	.00	0.1	0.8

FACETS 軟體提供 INFIT 和 OUTFIT 兩項適合度統計 (fit statistics) 來表示模式資料符合 (model-data fit) 的情形，其中 OUTFIT 值對於「偏離值 (outlier)」相當敏銳 (Linacre, 1999a)，可用於協助偵查或診斷不適合模式的資料 (Smith, 1996)。所謂不適合模式的資料，指的是受試者個人奇異的反應類型或非期望的表現或是能力不足之處 (Cole & Zhu, 1994)。

偏離反應值的期望值爲一，數值範圍從零到無限大，一般可接受的範圍在 0.8 到 1.2 附近。該數值些微的差距無從研判其差異，因此另呈現標準化分數以協助顯著水準與否之判讀，唯轉換後的標準化分數已失去原有精準性，可參考使用之 (Linacre, 1989)。偏離反應值小於 0.8 (或 0.7) 歸類爲木頭型 (Muted)，其反應局限於某一區域 (例如評審評給大部份考生相同等第，無法依據個別表現獨立有效評鑑高下)，如此縮小反應類別的情形，有助於降低變異但相對提供的訊息也少；偏離反應值大於 1.2 (或 1.3) 歸類爲吵鬧型 (Noisy)，顯示反應不當擴展，例如評審未依循客觀效標隨便給分、或受試者規律性答題 (如 030303 $\cdots$)，反應吵鬧沒有章法，致使變異加大，如同市場般吵鬧。後者通常是測量最不願見到的反應類型 (Linacre, 1999a, p.83)。

表二、裁判員層面估計摘要

裁判員	估計的能力	估計的標準誤	偏離反應	
			均方	標準化分數
台北	.00	.24	0.3	−3*
馬來西亞	.004	.24	0.5	−2*
韓國	.00	.24	0.7	−1
泰國	.00	.24	0.7	−1
新加坡	.00	.24	0.7	−1
英國	.00	.24	0.9	0
日本	.00	.24	1.0	0
香港	.00	.24	1.2	0
中國	.00	.24	2.7	4*
平均數	.00	.24	1.0	−0.5
標準差	.00	.00	0.7	2.0

*表示適合度統計的標準化分數之絕對值 ≥ 2。

表一舞蹈層面看來大致不錯, 表二裁判員層面中華台北籍和馬來西亞籍裁判偏離反應均方值低於期望值一太多, 標準化分數在 −2 以下, 顯示該員變異情形小, 提供的訊息量相對也變少; 香港籍和中國籍裁判偏離反應均方值則偏高, 變異情形大, 特別是中國籍裁判員尤高 (均方值 2.7, 標準化分數高達 +4), 疑爲不適合模式的資料, 應列爲注意觀察對象。

舞者層面,「估計的能力」值指的是舞者的「能力 (ability)」。依估計能力值排名 (詳如表三), 依次爲中華台北 121 隊 (表國別、背號, 下文不再複述)、中國 101 隊、中國 102 隊、泰國 124 隊、印尼 107 隊、泰國 125 隊。名次與亞運會比賽結果相同。

C.E.P.S.

表三、舞者層面估計摘要表

舞者 (國別、背號)	名次	估計的能力	估計的標準誤	偏離反應	
				均方	標準化分數
台北121	1	2.53	.20	1.9	3*
中國101	2	2.38	.19	0.9	0
中國102	3	1.004	.17	0.4	−3*
泰國124	4	−1.15	.18	0.8	0
印尼107	5	−1.34	.18	0.9	0
泰國125	6	−4.12	.35	0.9	0
平均數		−.12	.21	1.0	−0.4
標準差		2.35	.06	0.4	2.1

*表示適合度統計的標準化分數之絕對值 ≥ 2。

但是, 偏離反應值指示中華台北 121 隊和中國 102 隊適合度不良, 標準化分數之絕對值 ≥ 2, 且數值一正一負指示資料不適合模式的情形方向不同, 同樣列爲注意觀察對象。

表四、非期望反應摘要表

舞者 (國別、背號)	舞蹈	裁判員	評分排名	期望值	殘差	標準化殘差
中國102	華爾茲	香港籍	5	2.8	2.2	2
印尼107	華爾茲	香港籍	2	4.5	−2.5	−3
台北121	探戈	中國籍	4	1.7	2.3	3
台北121	維也納華爾茲	中國籍	4	1.7	2.3	3
台北121	慢狐步	中國籍	5	1.7	3.3	4
台北121	快步舞	中國籍	5	1.7	3.3	4

三個層面都說明過之後, 接著看「非期望反應 (unexpected responses)」(表四)。受試者「偏離應有的表現」稱爲「非期望反應」, 簡單的說即不當反應、失常或離譜。總共有六筆, 其標準化殘差值之絕對值均 ≥ 2 以上, 分述如下。

中國 102 隊和印尼 107 隊在華爾茲舞蹈各發生一次, 對象指向香港籍裁判員。此二次評判的殘差正好一正一負: 中國 102 隊名次的期望值 2.8 被評爲 5 (意即高水準表現, 低得分), 標準化殘差 +2; 印尼 107 隊名次的期望值 4.5 被評爲 2 (意即低水準表現, 高得分), 標準化殘差 −3。標準化殘差值的正負號指示高低判方向相反。

C.E.P.S.

非期望反應的出現可能導因於舞蹈 (相當於試題出得不好)、或舞者 (例如演出失常)、或裁判員 (例如誤判)。各種舞蹈的舞步、音樂明顯的不同, 參賽者對各舞蹈 (試題) 解讀應爲一致, 舞蹈層面初步可先排除。那到底是哪個層面引起的呢?

表五、非期望反應總評判表

舞者	舞蹈	統計值	裁判員								
			英	日	新	台	馬	泰	香	中	韓
中國102	華爾茲	原始排名	3	2	2	3	3	3	5	3	3
		期望值	2.8	2.8	2.8	2.8	2.8	2.8	2.8	2.8	2.8
		標準化殘差	0	0	0	0	0	0	2*	0	0
印尼107	華爾茲	原始排名	4	5	4	4	4	6	2	4	5
		期望值	4.5	4.5	4.5	4.5	4.5	4.5	4.5	4.5	4.5
		標準化殘差	0	0	0	0	0	1	−3*	0	0
台北121	探戈	原始排名	2	1	1	1	1	2	1	4	1
		期望值	1.7	1.7	1.7	1.7	1.7	1.7	1.7	1.7	1.7
		標準化殘差	0	0	0	0	0	0	0	3*	0
台北121	維也納	原始排名	2	1	1	1	1	2	1	4	1
	華爾茲	期望值	1.7	1.7	1.7	1.7	1.7	1.7	1.7	1.7	1.7
		標準化殘差	0	0	0	0	0	0	0	3*	0
台北121	慢狐步	原始排名	2	1	1	1	1	3	1	5	1
		期望值	1.7	1.7	1.7	1.7	1.7	1.7	1.7	1.7	1.7
		標準化殘差	0	0	0	0	0	1	0	4*	0
台北121	快步舞	原始排名	2	2	2	1	2	2	1	5	2
		期望值	1.7	1.7	1.7	1.7	1.7	1.7	1.7	1.7	1.7
		標準化殘差	0	0	0	0	0	0	0	4*	0

*表標準化殘差之絕對值 ≥ 2 以上。

在正式進入討論之前先說明一下裁判行爲: 裁判員採自由心證沒有評分標準, 且規定強迫排名 (名次不得並列), 過半數的裁判員看法一致時即可獲得該項比賽冠軍 (楊昌雄, 民 89)。換言之, 競賽採「主觀評分」, 以「多數決」爲判行標準。

接續前文, 於是追溯到非期望反應發生時點 (表五), 發現中國 102 隊在華爾茲舞蹈一項的排名應在二、三名之譜, 而香港籍裁判卻評爲第五, 明顯與其他多數裁判員南轅北轍, 依多數決標準推論其應屬不良之低判。該一判決離譜太多致使其標準化殘差之絕對值 ≥ 2 以上, 因而列爲「非期望反應」判決。由此得知非期望反應導因於裁判員不

當反應。

印尼 107 隊的情況類似, 屬於不良之高判。香港籍裁判因爲此二次非期望反應判決導致偏離反應均方值偏高而顯得適合度不良, 與表二的結果相吻合。

這二次的非期望反應判決僅發生在華爾茲舞蹈一項, 沒有固定對象, 且高、低判正巧各一次, 其發生的原因可能爲「筆誤」或「誤判」或其他因素所致。

導因於中國籍裁判員之非期望反應計四次 (表四), 對象一致爲中華台北 121 隊, 發生的舞蹈是探戈、維也納華爾茲、慢狐步和快步舞, 僅華爾茲一項沒有。四次評判的期望值均爲 1.7, 原始排名爲 4、4、5、5, 標準化殘差高達 +3 以上, 方向一致爲低判。同樣追溯其發生時點 (表五), 發現中華台北 121 隊在四項舞蹈的排名應在一、二名之譜, 而中國籍裁判卻評爲第四和第五, 按競賽規則「多數決」判行標準, 均屬不良之低判。四次判決離譜太多而同被標示爲「非期望反應」判決。

前文曾提及『中華台北 121 隊適合度不良 ···』(表三)、『中國籍裁判偏離反應值尤高, 列爲注意觀察對象...』(表二), 主要原因應爲此四次非期望反應判決所致, 在此我們得到了解答。

中國籍裁判的非期望反應判決重複地發生在四項舞蹈, 對象固定爲中華台北, 方向一致爲低判。中共向來刻意打壓台灣, 對於體育活動仍是多方阻擾 (黃永旺, 民 87), 在此又添一例。撇開政治純就測量而言, 當裁判員重複、規律地出現 (非隨機) 非期望反應判決, 失卻客觀立場, 形成「系統性誤差」, 該員已喪失擔任裁判工作之資格, 應排除於裁判席之外。

第四節　結論

本研究採用試題反應理論分析裁判的判決, 以第十三屆亞運會舞蹈運動標準舞比賽決賽裁判員裁決情形爲分析資料, 利用 FACETS 軟體進行多層面 Rasch 模式分析, 檢定「適合度統計」、「非期望反應」。分析發現有二位裁判員屬吵鬧類型及六個非期望反應, 再細究非期望反應的原因應爲「系統性誤差」、「誤判」或「筆誤」所致。研究結果證實此二位裁判員評判不公, 且其偏離程度之輕重則可以殘差加以標示之。

C.E.P.S.

參考文獻

一、中文部分

中國時報 (民 91)。冬運花絮-補領金牌俄觀禮, 2 月 18 日 30 版。台北, 中國時報。

自由時報 (民 91)。評審不公, 法輿論譁然, 2 月 17 日 19 版。台北, 自由時報。

何榮桂、姚漢禱 (民 85)。評分量尺模式在運動技能測驗上的應用。**中國測驗學會測驗年刊**, 43 輯, 141 - 152 頁。

林德隆 (民 88)。利用試題反應理論編製國中壘球擲準測驗。**大專體育學刊**, 1 卷 2 期, 11 - 24 頁。

黃永旺 (民 87)。中共阻擾兩岸體育交流事件之探討。**國立體育學院論叢**, 8 卷 2 期, 103 - 130 頁。

楊昌雄 (民 89)。第十三屆亞洲運動會舞蹈運動比賽裁判分析。**中華體育季刊**, 13 卷 4 期, 36 - 43 頁。

葉憲清、姚漢禱 (民 89)。**選手評鑑運動教練的多層面 Rasch 測量分析**。行政院國家科學委員會專題研究計畫成果報告, NSC 89 - 2413 - H - 179 - 001 。

二、英文部分

Cole, E., & Zhu, W. (1994). IRT person fit statistics to diagnose motor function. *Research Quarterly for Exercise and Sport, March* 1994 *Supplement*, A-61.

Engelhard, G. (1992). The measurement of writing ability with a many-faceted Rasch model. *Applied Measurement in Education*, 5(3), 171-191.

Linacre, J.M. (1989). *Many-facet Rasch measurement.* Chicago: MESA Press.

Linacre, J.M. (1999a). *A user's guide to* FACETS: *Rasch measurement computer program.* Chicago: MESA Press.

Linacre, J.M. (1999b). FACETS: *Rasch measurement computer program* (Version 3.20). Chicago:MESA Press.

C.E.P.S.

Looney, M.A. (1996). Figure skating fairness. *Rasch Measurement Transactions*, 10 (2), 500.

Lunz, M.E., Wright, B.D., & Linacre, J.M. (1990). Measuring the impact of judge severity on examination scores. *Applied Measurement in Education*, 3 (4), 331 - 345.

Smith, R.M. (1996). Polytomous mean-square fit statistics. *Rasch Measurement Transactions*, 10 (3), 516 - 517.

Wright, B.D., & Masters, G.N. (1982). *Rating scale analysis.* Chicago: MESA Press.

C.E.P.S.

Who is unfair ?

Meng-Pao Tseng

Abstract

The purpose of this study was to analyze the judge's rating in terms of item response theory. The data of the evaluation of standard dance's judge in the final of the 13th Asian Games was analyzed. The FACETS software was used to analyze three-facet Rasch model, testing "fit statistics" and "unexpected responses". The results showed that there were two unfair judges and six "unexpected responses". The unexpected responses had been explained by systematic error, misjudging and slipping of pen.

Keywords: item response theory, judge's rating, dance sport, fit statistics.

C.E.P.S.